

Percepção Multimodal para Interação Social em Robótica Através de Compreensão Visual-Linguística

membro: Ervin Alain Bolivar H.

Primeira Entrega

Descrição do Projeto


- Objetivo
 - Investigar um **sistema cognitivo de percepção multimodal** em uma cabeça robótica Pan-Tilt **para melhorar a qualidade das interações sociais** entre humanos e robôs.
- Motivação
 - Fazer com que o robô não apenas **escute** ou **fale**, mas que "**olhe com intenção**", gerando uma **atenção visual coerente** com o conteúdo conversacional.
- Por que é importante?
 - Atenção visual intencional → mais natural e humana
 - Conexão semântica → linguagem + visão integradas
 - Interação social aprimorada → comunicação não verbal efetiva

Metodologia

Sistema multimodal simulador–embebido, compuesto por tres módulos coordinados:

- percepción visual
- lenguaje natural
- control físico de cabeza robótica.
- **Vision-Language Model (VLM):** CLIP o SigLIP como backbone para generar embeddings visuales y embeddings textuales alineados. Esto permitirá comparar conceptos como "persona con gorro rojo" [OpenAI, 2021] e [Touvron et al., 2023]).
- **LLM + STT:** Whisper para convertir voz a texto, y un LLM liviano (como Gemma 2B o Phi-3-mini) para inferir la intención lingüística y extraer la referencia semántica. ("persona com muleta", "homem de boné", etc.).
- **Controlador Pan-Tilt:** Se diseñará un generador de comandos discretos (up/down/left/right)

Metodologia



Pipeline Experimental

- **Entrada: Voz do usuário** → Whisper (STT)
- **Processamento: texto** → LLM → extração de intenção
- **Embedding textual** → VLM
- Embeddings visuais dos candidatos na imagem
- Similaridade cosseno (texto ↔ imagem)
- Seleção do objetivo mais provável
- **Comando Pan-Tilt** → movimento da cabeça

Datasets (Públicos)

Detecção de Pessoas

WIDER-Attribute → atributos físicos (chapéu, óculos, etc)



Multimodal (Texto ↔ Imagem)

Flickr30k → descrições alinhadas a regiões da imagem



A man with **pierced ears** is wearing **glasses** and an **orange hat**.
A man with **glasses** is wearing a beer can crocheted hat.
A man with **glasses** and **glasses** is wearing a Blitz hat.
A man in an **orange hat** staring at **something**.
A man wears an **orange hat** and **glasses**.

Seguimento Visual

RefVOS → vídeos com instruções verbais + segmentação



Métricas

- Semântica
 - Cosine Similarity: alinhamento texto ↔ imagem
- Seguimento Visual
 - Success Rate: % frames centralizados
 - Precision: erro médio em pixels
- Controle Pan-Tilt
 - Angular Error: erro angular (graus)
 - Latency: tempo de reação

Categoria	Métrica	O que mede
Semântica	Cosine Similarity	Alinhamento texto ↔ visual
Tracking	Success Rate	% frames centralizados
Tracking	Precision	Erro em pixels
Pan-Tilt	Angular Error	Erro angular (graus)
Pan-Tilt	Latency	Tempo de resposta

Resultados

1. Compreensão Referencial

✓ Cosine Similarity > 0.75

Validação do alinhamento semântico linguagem ↔ visão

2. Seguimento Visual Estável

✓ Success Rate $\geq$ 85%

3. Controle Pan-Tilt Natural

✓ Angular Error < pequeno menor a 10°

✓ Latência < pequena aproximadamente 1 segundo

Validação: Sistema capaz de compreender instruções naturais, identificar objetivos via embeddings e executar movimentos socialmente coerentes.

Referências

Learning Transferable Visual Models From Natural Language Supervision

Alec Radford, Jong Wook Kim, Chris Hallacy et al.

OpenAI – 2021 <https://arxiv.org/abs/2103.00020>

SigLIP: Scaling and Improving Vision-Language Models with Image Prefixes

Hugo Touvron, Francisco Massa, Nicolas Carion et al.

Meta AI – 2023 <https://arxiv.org/abs/2303.15343>

A3VLM: Adaptive Agent for Vision-Language-Action Navigation via Multimodal Reasoning

Xin Huang, Tao Wang, Qi Wu, and Xin Eric Wang

ECCV – 2024 <https://arxiv.org/abs/2403.05728>

Cronograma

Lista de atividades a serem feitas antes de cada entrega:

- 30 de Outubro - entrega I - Plano de Trabalho
- 6 de Novembro - entrega II - ...
- 13 de Novembro - entrega III - ...
- 27 de Novembro - entrega final - ...

Título do Projeto

membro(s):

Segunda Entrega

