

**UNIVERSIDADE ESTADUAL DE CAMPINAS**  
**INSTITUTO DE COMPUTAÇÃO**

**MO656 - INTRODUÇÃO À WEB SEMÂNTICA**

Prof. Dr. Julio Cesar dos Reis

**FASE 1**

Proposta de Projeto

**Aluno:** Ervin Alain Bolivar Huayhua

Campinas  
28 de agosto de 2025

# Representação Semântica de Interações Multimodais em Ambientes Inteligentes

## 1. Contexto e Motivação

---

Nos últimos anos, venho acompanhando o avanço de tecnologias digitais que transformam a forma como interagimos com máquinas. Casas inteligentes, ambientes educacionais conectados e robôs de serviço começaram a ocupar um espaço cada vez mais visível em nosso cotidiano, e junto com eles cresce a expectativa de que essas tecnologias possam compreender nossas necessidades de maneira natural, respondendo à fala, a gestos e até mesmo ao nosso estado emocional. Esse cenário de inovação constante abre oportunidades importantes para repensar como construímos sistemas capazes de apoiar pessoas em tarefas diárias e em contextos colaborativos.

Mas, à medida que observo a evolução desses sistemas, percebo que há um descompasso entre a promessa e a realidade. Robôs e dispositivos IoT conseguem captar dados multimodais — sons, imagens, comandos verbais —, mas raramente conseguem interpretá-los de forma integrada e coerente. Essa limitação compromete o potencial de ambientes inteligentes, pois, apesar de toda a infraestrutura tecnológica disponível, ainda é comum que comandos simples sejam mal interpretados ou ignorados. Essa fragilidade de compreensão leva a frustrações por parte dos usuários, que muitas vezes se veem obrigados a repetir instruções ou realizar manualmente aquilo que a tecnologia deveria facilitar.

Portanto, minha motivação ao desenvolver esta proposta nasce da necessidade de enfrentar essa lacuna de compreensão contextual. Acredito que é essencial investigar como integrar diferentes modalidades de interação (fala, gestos e dados ambientais) em uma estrutura semântica capaz de apoiar o raciocínio de sistemas robóticos. Mais do que oferecer respostas automáticas, trata-se de criar uma base de conhecimento compartilhada que permita ao sistema compreender quem está falando, o que está sendo solicitado, em que contexto isso ocorre e com qual finalidade. Dessa forma, é possível avançar rumo a ambientes mais confiáveis, nos quais a tecnologia realmente amplia a autonomia e a qualidade de vida das pessoas.

Essa motivação também se conecta diretamente com os Objetivos de Desenvolvimento Sustentável (ODS). Em particular, o ODS 9 (Indústria, Inovação e Infraestrutura) orienta iniciativas que buscam fortalecer capacidades tecnológicas e estimular inovação em setores estratégicos, enquanto aponta para a importância de ambientes inteligentes que apoiem processos de ensino e aprendizagem. Considero que meu projeto dialoga com esses dois objetivos: ao mesmo tempo em que contribui para a inovação em robótica e Internet das Coisas, também tem potencial para impactar positivamente contextos educacionais, nos quais robôs podem atuar como facilitadores de

interação e aprendizagem.

Em síntese, minha motivação está em construir um caminho que una a capacidade linguística dos modelos de linguagem com a robustez estrutural dos grafos de conhecimento, oferecendo aos sistemas IoRT um entendimento mais profundo do contexto em que operam. Assim, acredito ser possível superar limitações atuais e aproximar a experiência de uso daquilo que realmente esperamos de uma tecnologia inteligente: flexibilidade, confiabilidade e relevância no apoio às nossas atividades cotidianas.

## 2. Caracterização do Problema e Escopo

---

Nos últimos anos, tenho acompanhado a expansão de casas inteligentes e de laboratórios colaborativos equipados com robôs e dispositivos conectados. A promessa apresentada é atraente: ambientes nos quais assistentes virtuais, robôs móveis e sensores IoT funcionam de forma integrada, compreendendo nossa fala e nossos gestos para facilitar e tornar mais seguro o cotidiano. Entretanto, na prática observo um cenário distinto: tais sistemas ainda não conseguem interpretar o contexto de maneira unificada, frequentemente falhando na compreensão de interações multimodais realizadas pelos usuários. Em diversas ocasiões, já vivenciei situações em que, ao emitir um comando de voz acompanhado de um gesto, o robô executou uma ação equivocada ou permaneceu inerte. Essas falhas recorrentes comprometem a realização das tarefas esperadas e produzem um sentimento de frustração que afeta tanto a mim quanto a outros usuários. Portanto, a experiência inicialmente prometida de assistência fluida acaba prejudicada, abalando a confiança na tecnologia e levantando questionamentos sobre sua real eficiência.

Para ilustrar, considero um cenário em uma casa assistiva inteligente. No momento de tomar a medicação, uma moradora idosa solicita ao robô humanoide: “Por favor, traga o remédio”, enquanto aponta para a prateleira. O ambiente, equipado com câmeras, microfones e dispositivos conectados, deveria ser capaz de interpretar corretamente tal pedido. No entanto, percebo a hesitação do robô, que compreende a frase, mas não associa a instrução ao gesto nem ao contexto de que a senhora ingere o medicamento todas as noites. O resultado é um pedido de esclarecimento por parte da máquina ou, em casos mais graves, a entrega de um objeto incorreto. Após sucessivas tentativas frustradas, a usuária opta por buscar o medicamento sozinha, sentindo-se irritada com as limitações do ambiente. Esse exemplo, longe de ser uma ficção, evidencia o problema central: mesmo com múltiplos agentes físicos e sensores distribuídos, os sistemas não conseguem compreender de forma coletiva e integrada o que o usuário expressa por meio da comunicação natural.

A origem dessa dificuldade encontra-se na limitação atual dos sistemas em integrar dados provenientes de diferentes modalidades em uma interpretação única e coerente. Assistentes de voz comerciais são capazes de atender a comandos simples como “ligar a luz”, mas apresentam difi-

culdade em lidar com pedidos mais complexos ou subjetivos, como “deixe o quarto mais aconchegante”. Com frequência, nós, usuários, precisamos adaptar nossa forma de comunicação às máquinas, simplificando ou repetindo instruções, em vez de elas se ajustarem à linguagem natural com que nos expressamos. Solicitações incompletas ou implícitas, que seriam facilmente compreendidas por um interlocutor humano, frequentemente não são processadas pelos sistemas, resultando em erros e na consequente frustração dos usuários. Em contextos com múltiplos agentes, a situação se torna ainda mais crítica: cada robô ou dispositivo “enxerga” apenas parte do cenário e, sem uma visão unificada, acabam agindo de maneira inconsistente ou simplesmente não agem.

As consequências desse descompasso são significativas. Percebo que a eficiência prometida por esses ambientes se reduz de forma acentuada: atividades simples tornam-se processos cheios de atrito, exigindo maior tempo e esforço do usuário. A frustração decorrente desses mal-entendidos compromete a confiança na tecnologia, elemento essencial para sua adoção. Pesquisas na área de interação humano-robô confirmam que experiências negativas geram queda de produtividade, reduzem a satisfação dos usuários e fragilizam a confiança depositada nos sistemas. Essa confiança, uma vez abalada, é difícil de restabelecer, e cada falha reforça a resistência em depender da tecnologia em situações críticas. Em ambientes assistivos, esse quadro se agrava: usuários podem evitar pedir ajuda ao robô por já presumirem que não serão compreendidos, colocando-se em risco ao tentar realizar tarefas sem apoio.

Escopo: Diante desse contexto, defino que o escopo do presente projeto concentra-se no desafio da compreensão multimodal em ambientes inteligentes. O foco será analisar como a ausência de integração entre fala, gestos, ambiente e histórico de interações compromete a experiência do usuário e limita o potencial dessas tecnologias. Outros aspectos, como falhas mecânicas dos robôs ou questões de segurança de rede, não fazem parte deste recorte. Assim, a investigação buscará caracterizar cenários em que ocorrem mal-entendidos entre humanos e agentes, com vistas a esclarecer quais lacunas de entendimento precisam ser abordadas para que a promessa desses sistemas seja efetivamente cumprida.

## **2.1. Partes Interessadas**

O primeiro perfil afetado é o usuário final do ambiente inteligente. Podemos imaginar o caso de Dona Maria, uma senhora de 70 anos que vive sozinha em uma casa equipada com robô assistivo e dispositivos IoT. Para ela, a tecnologia simboliza autonomia e conforto, permitindo controlar eletrodomésticos por voz e contar com o auxílio do robô em atividades cotidianas. Contudo, quando suas solicitações não são compreendidas, a experiência se transforma em fonte de frustração e insegurança. Repetir comandos várias vezes, sem obter resposta satisfatória, leva à perda gradual de confiança e ao abandono do uso da tecnologia, prejudicando diretamente sua qualidade de vida.

Um segundo perfil é o do cuidador ou familiar. No exemplo de Dona Maria, sua filha Ana con-

fiou na automação para garantir maior segurança à mãe. Entretanto, ao perceber a recorrência de falhas, Ana passa a duvidar da confiabilidade do sistema. Essa situação gera ansiedade e preocupação, sobretudo em casos de emergência, quando a incapacidade de o sistema compreender corretamente um pedido pode ter consequências sérias.

Por fim, destaco a equipe técnica e os desenvolvedores responsáveis pelo projeto. Esse grupo enfrenta o desafio de conciliar altas expectativas dos usuários com limitações práticas das soluções atuais. Relatos de falhas e feedbacks negativos evidenciam que, apesar dos avanços alcançados, o sistema ainda não atende às necessidades básicas de interpretação do contexto. Isso gera pressão adicional sobre a equipe, que se vê obrigada a repensar abordagens e buscar alternativas para aumentar a aceitação e credibilidade da tecnologia.

### **3. Definição dos Objetivos**

---

#### **3.1. Objetivo Geral**

O objetivo principal deste projeto é desenvolver e validar um framework conceitual que integre grafos de conhecimento e modelos de linguagem em sistemas IoRT, de modo a permitir uma interpretação mais contextualizada das interações multimodais (fala, gestos e sinais do ambiente) e apoiar a execução de tarefas em ambientes inteligentes. Busca-se demonstrar que a combinação de técnicas da Web Semântica com capacidades de raciocínio de LLMs pode aumentar a eficiência, a confiança e a adaptabilidade desses sistemas.

#### **3.2. Objetivos Específicos**

1. Construir uma ontologia modular que represente participantes, interações, objetos, tarefas e estados do ambiente em cenários IoRT.
2. Povoar um grafo de conhecimento RDF com dados simulados que reflitam interações reais entre usuários, robôs e dispositivos IoT.
3. Definir e executar consultas SPARQL que permitam recuperar informações relevantes do grafo, tais como intenções do usuário, estados de dispositivos ou histórico de interações.
4. Avaliar um protótipo conceitual em ROS 2, integrando parcialmente a ontologia e o grafo de conhecimento com a simulação de agentes físicos, de forma a verificar a aplicabilidade do modelo em contextos robóticos.

### 3.3. Conexão com Técnicas e Modelos da Web Semântica

Os objetivos propostos estão diretamente alinhados às técnicas centrais da Web Semântica. A construção da ontologia será realizada em OWL/RDFS, definindo classes, propriedades e axiomas que organizam o domínio da interação humano-robô. O povoamento do grafo de conhecimento seguirá o modelo RDF, permitindo a representação formal de indivíduos, relações e eventos. A exploração dos dados ocorrerá por meio de consultas SPARQL, que viabilizam responder a questões complexas sobre o ambiente e as interações.

A adoção dessas tecnologias tem como finalidade garantir interoperabilidade, consistência e inferência automática, permitindo que os sistemas possam derivar novos conhecimentos a partir de fatos conhecidos. Além disso, a integração com ROS 2 reforça a relevância prática do projeto, aproximando os conceitos da Web Semântica da robótica aplicada. Dessa forma, a proposta busca não apenas atender aos requisitos da disciplina, mas também contribuir para a evolução de soluções híbridas que combinem LLMs e KGs em cenários IoRT.

## 4. Proposta de Solução Conceitual

---

Nesta primeira fase, a proposta de solução conceitual parte da constatação de que ambientes inteligentes com múltiplos agentes físicos e dispositivos IoT ainda enfrentam sérias limitações na compreensão de interações multimodais. A intenção inicial é investigar como técnicas da Web Semântica podem apoiar a organização e o raciocínio sobre esse contexto, fornecendo uma estrutura capaz de ser explorada por modelos de linguagem para interpretar e planejar ações de forma mais contextualizada.

O projeto será orientado por um framework conceitual que articula três componentes centrais: (i) a representação semântica do ambiente, por meio de ontologias e grafos de conhecimento; (ii) a exploração de consultas semânticas para recuperar informações relevantes ao estado atual do sistema; e (iii) a interação com modelos de linguagem que possam interpretar esses dados e apoiar o planejamento de tarefas. Esta estrutura deve permitir que informações sobre usuários, dispositivos, objetos e diálogos sejam capturadas em um grafo RDF, enriquecidas com vocabulários OWL e acessadas por consultas SPARQL.

Ainda não está definido se a ontologia será construída totalmente do zero ou se será adaptada a partir de modelos existentes, como CORA, KnowRob ou SAREF. A decisão dependerá das próximas leituras, discussões em aula e experimentos iniciais. Da mesma forma, a extensão da integração com ROS 2 permanece em aberto: neste momento, considera-se a possibilidade de desenvolver um protótipo simplificado em simulação, mas sem compromisso de implementação plena nesta fase.

Como entregáveis preliminares, vislumbro: uma ontologia modular em OWL que represente

elementos básicos do domínio; um grafo RDF com dados simulados de um ambiente inteligente; consultas SPARQL que demonstrem a recuperação de informações contextuais; e, se viável, um protótipo conceitual em ROS 2 que integre parcialmente essas componentes. Ressalto, entretanto, que esses entregáveis podem ser ajustados ou refinados à medida que a disciplina avançar e novos conceitos forem explorados.

Portanto, a proposta de solução nesta etapa deve ser compreendida como um esboço inicial de um caminho de investigação. Ela não fecha metodologias, tecnologias ou limites definitivos, mas estabelece uma direção: explorar como a Web Semântica pode fornecer a base estrutural necessária para enriquecer a interpretação multimodal em sistemas IoRT, preparando terreno para fases posteriores em que os detalhes técnicos serão gradualmente definidos e implementados.

## 5. Posicionamento com o Estado da Arte

---

Ao revisar a literatura existente, percebo que há uma base sólida de trabalhos que exploram o uso de ontologias e grafos de conhecimento na robótica, cada um oferecendo contribuições específicas. Projetos como CORA (Core Ontology for Robotics and Automation) estabelecem conceitos fundamentais de robôs, sensores e tarefas, servindo como referência padronizada no domínio. Já iniciativas como o KnowRob mostram a viabilidade de integrar ontologias em sistemas robóticos, permitindo que informações de alto nível sejam usadas para apoiar decisões em tarefas de serviço. Da mesma forma, ontologias como a SAREF, voltadas para dispositivos IoT, evidenciam o potencial de alinhar ambientes inteligentes a vocabulários interoperáveis, ampliando a integração com sensores e atuadores distribuídos.

Além disso, identifico estudos recentes que buscam unir modelos de linguagem a estruturas semânticas. Esses trabalhos reforçam que os LLMs, embora poderosos para interpretação linguística, necessitam de apoio de representações formais para evitar ambiguidades e assegurar consistência nas decisões. Nesse sentido, algumas propostas mais atuais exploram como ontologias de ações robóticas podem ser utilizadas para traduzir comandos em rotinas executáveis, aproximando a linguagem natural de operações físicas em robôs humanoides.

Apesar desses avanços, noto que ainda há um espaço relevante de investigação quando pensamos em ambientes multimodais e multiagentes, como no caso de sistemas IoRT em cenários assistivos ou educacionais. A maior parte dos trabalhos concentra-se em domínios específicos (robótica doméstica, colaboração industrial, IoT isolada), mas poucos abordam a integração de múltiplos elementos — conversação, emoção, sensores e planejamento adaptativo — em uma única estrutura semântica apoiada por LLMs.

Diante disso, posiciono minha proposta como um esforço de articulação entre diferentes linhas já consolidadas, mas ainda de forma exploratória nesta fase. Não busco substituir ou reinventar

modelos existentes, mas compreender de que maneira frameworks como CORA, KnowRob ou SAREF podem ser adaptados e combinados para atender ao cenário específico de interação multimodal em ambientes inteligentes. Também considero fundamental observar como técnicas de consulta semântica (SPARQL) podem dialogar com modelos de linguagem para formar um ciclo de interpretação e ação mais robusto.

Em suma, o estado da arte indica caminhos e inspirações já bem fundamentados, mas também evidencia lacunas que justificam a investigação. Minha proposta nesta etapa inicial é justamente mapear essas referências e identificar quais delas se mostram mais promissoras para integrar em um protótipo conceitual. O posicionamento, portanto, é deliberadamente aberto e flexível, reconhecendo que a definição final das tecnologias e metodologias será construída ao longo das próximas fases da disciplina.



## Referências

---

GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliu; BI, Yuxi; DAI, Yixin; SUN, Jiawei; WANG, Haofen. Retrieval-augmented generation for large language models: A survey. **arXiv preprint**, arXiv:2312.10997, v. 2, n. 1, 2023.

GÓMEZ, L. Villamar; MIURA, Jun. Ontology learning of new concepts combining textural knowledge and visual analysis for service robot applications. In: IEEE INTERNATIONAL CONFERENCE ON INTELLIGENCE AND SAFETY FOR ROBOTICS (ISR), 2021, Proceedings... IEEE, 2021. p. 98-100.

PAPANASTASIOU, Stergios; KOUSI, Niki; KARAGIANNIS, Panagiotis; GKOURNELOS, Christos; PAPAVASILEIOU, Apostolis; DIMOULAS, Konstantinos; BARIS, Konstantinos; KOUKAS, Spyridon; MICHALOS, George; MAKRIS, Sotiris. Towards seamless human robot collaboration: integrating multimodal interaction. **The International Journal of Advanced Manufacturing Technology**, v. 105, n. 9, p. 3881-3897, 2019.

XU, Zhentao; CRUZ, Mark Jerome; GUEVARA, Matthew; WANG, Tie; DESHPANDE, Manasi; WANG, Xiaofeng; LI, Zheng. Retrieval-augmented generation with knowledge graphs for customer service question answering. In: INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 47., 2024, Proceedings... ACM, 2024. p. 2905-2909.

YAO, Shunyu; ZHAO, Jeffrey; YU, Dian; DU, Nan; SHAFRAN, Izhak; NARASIMHAN, Karthik; CAO, Yuan. React: Synergizing reasoning and acting in language models. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 2023, Proceedings... ICLR, 2023.