

UNIVERSIDADE ESTADUAL DE CAMPINAS
INSTITUTO DE COMPUTAÇÃO

MO656 - INTRODUÇÃO À WEB SEMÂNTICA

Prof. Dr. Julio Cesar dos Reis

FASE 2

Proposta de Projeto

Aluno: Ervin Alain Bolivar Huayhua

Campinas
13 de setembro de 2025

Representação Semântica de Interações Multimodais em Ambientes Inteligentes

1. Preparação de dados

A etapa inicial envolve a definição do alcance semântico do ambiente inteligente, estabelecendo quais entidades, relações e funções serão modeladas. Isso inclui agentes (humanos, físicos e cognitivos), objetos manipuláveis, espaços como salas e zonas de interação, além das ações possíveis em cada contexto. Essa delimitação garante que a representação de dados seja precisa e útil para aplicações posteriores, evitando redundâncias e inconsistências. Modelos como o *upper ontology* de *KnowRob* e vocabulários como *SAREF* fornecem diretrizes para organizar esses elementos de forma interoperável.




Figura 1: Hierarquia das ontologias DOLCE/DUL → SOMA → KnowRob → SAREF com 64 conceitos e 78 relações semânticas

A Figura 1 ilustra a arquitetura hierárquica de quatro ontologias para sistemas inteligentes, desde DOLCE/DUL (base fundacional) até SAREF (aplicações IoT), passando por SOMA (atividades sócio-físicas) e KnowRob (robótica autónoma). Esta estrutura organiza 64 conceitos em

níveis crescentes de especialização, interligados por 78 relações semânticas que asseguram a interoperabilidade entre domínios abstratos e aplicações práticas.

Os dados são coletados a partir de múltiplas fontes, refletindo a complexidade do ambiente inteligente. Observações dinâmicas do ambiente são obtidas por dispositivos IoT (sensores de movimento, câmeras, microfones, atuadores), agentes físicos (robôs móveis, braços robóticos e assistentes sociais como robô SAM) e interações de usuários humanos, por meio de comandos em linguagem natural e perfis de necessidades. Além disso, são incorporados conhecimentos de domínio representados em ontologias existentes, como *KnowRob*, e documentação textual processada via módulos *RAG* para enriquecer o suporte explicativo. Essa combinação fortalece a base semântica e possibilita inferências contextuais robustas.

Após a coleta, os dados passam por um processo de preparação que assegura sua consistência semântica. Inicialmente, realiza-se a normalização e padronização em formatos como *JSON-LD* e *RDF/Turtle*, estabelecendo uma estrutura comum para integração. Cada entidade recebe URIs únicas e persistentes, permitindo rastreabilidade de objetos, agentes, salas e eventos. Em seguida, os dados são enriquecidos com anotações semânticas usando vocabulários reconhecidos, como *SAREF*, *KnowRob* e *Schema.org*, ampliando sua interoperabilidade na Web Semântica. Por fim, aplicam-se regras de validação baseadas em *SHACL* para garantir a integridade dos grafos RDF, reduzindo erros e assegurando conformidade estrutural.

2. Metodologia de Implementação e Aplicação das Técnicas de Web Semântica

2.1. Ontologias e modelagem semântica

Para estruturar o conhecimento do ambiente inteligente, são empregadas ontologias de referência que asseguram padronização e interoperabilidade. O *KnowRob* fornece classes e relações voltadas para objetos e ações em cenários robóticos, enquanto a *SAREF* é aplicada para a descrição de dispositivos e recursos IoT. Adicionalmente, a *OWL-Time* garante a representação formal da dimensão temporal de eventos e estados. O modelado semântico baseia-se em *RDF* e *OWL*, permitindo representar entidades, propriedades e restrições de forma explícita. Esse uso combinado de vocabulários possibilita alinhar diferentes fontes de dados sob um mesmo grafo de conhecimento, facilitando consultas e inferências robustas.

2.2. Modelagem de objetos, lugares e agentes

A etapa de modelagem transforma elementos do ambiente em entidades semânticas identificáveis. Objetos físicos, como dispositivos e recursos (ex.: *Lampada01*, *RoboMovel_p3dx*), são representados com propriedades funcionais e de estado. Espaços físicos, como salas ou laboratórios, são des-

critos como instâncias com localização e função. Já os agentes abrangem humanos, robôs móveis, manipuladores e processos cognitivos, incluindo suas capacidades e papéis em tarefas colaborativas. Essa categorização explícita facilita que o grafo de conhecimento represente não apenas a estrutura do ambiente, mas também sua dinâmica operacional, criando uma base para raciocínio automático e coordenação entre múltiplos agentes.




Figura 2: Grafo RDF do ambiente doméstico com objetos (retângulos azuis), lugares (retângulos verdes arredondados) e agentes (círculos laranjas).

Na Figura 2 apresenta-se um grafo RDF simplificado que descreve a relação entre salas (verde), objetos (azul) e agentes (laranja). Os espaços físicos, como `kitchen` e `living_room`, funcionam como nós de referência, enquanto objetos e agentes são ligados por propriedades como `:locatedIn` ou `:onTopOf`. Essa representação semântica organiza o ambiente de forma clara e favorece o raciocínio automático.

2.3. Raciocínio semântico

O raciocínio sobre o grafo ocorre por meio da definição de precondições e efeitos de ações, como em *PickUpCup* ou *TurnOnLight*, associando estados iniciais a resultados esperados. Essa formalização permite inferir quais ações estão disponíveis em determinado contexto: por exemplo, se *Lampada01* possui *:hasStatus* “off”, então a ação possível é *TurnOn*. Além disso, mecanismos de

inferência permitem deduzir estados implícitos, verificar consistência e antecipar falhas ou necessidades. O raciocínio semântico amplia a autonomia dos sistemas, pois garante que robôs e agentes IoT reajam a mudanças de forma coerente com regras lógicas e objetivos globais.

2.4. Construção e uso de grafos de conhecimento

A integração das ontologias e dos dados capturados resulta em um grafo de conhecimento *RDF* centralizado, atualizado dinamicamente conforme robôs e sensores registram mudanças no ambiente. Esse modelo busca superar a fragmentação de dados heterogêneos e criar uma representação unificada, permitindo que agentes humanos e artificiais operem sobre uma visão semântica comum do contexto. Consultas *SPARQL* fornecem mecanismos formais para recuperar fatos ou verificar condições de execução, enquanto regras de inferência ampliam a capacidade de raciocínio sobre a cena. Entre as principais regras que estruturam o funcionamento do grafo, destacam-se:

- Regras de localização espacial: determinam em qual sala ou espaço cada agente ou objeto está. Exemplo: se o agente *ervin_bolivar* está localizado na *kitchen*, o sistema infere que pode interagir com objetos presentes nessa sala.
- Regras de suporte e contato: descrevem relações físicas, como um objeto apoiado sobre outro. Exemplo: se um *plate* está sobre o robô *Pioneer3DX*, o raciocínio conclui que o prato se moverá junto com o robô.
- Regras de acessibilidade e *affordances*: inferem quais ações são possíveis com base na posição e categoria dos objetos. Exemplo: um *cup* acessível ao robô manipulador *kinova* é marcado como *pickable*, indicando que pode ser agarrado.
- Regras temporais: analisam permanência ou duração de eventos em determinados ambientes. Exemplo: se *eric_rohmer* permanece mais de 30 minutos na *living_room* sem movimento, pode-se inferir inatividade anômala.
- Regras de consequência de ação: atualizam automaticamente o estado dos objetos após interações. Exemplo: se um usuário executa *open(fridge)*, o grafo atualiza o estado do *fridge* para *open*.
- Regras de segurança e alerta: disparam mecanismos de assistência quando situações críticas são detectadas. Exemplo: se sensores indicam *fallDetected(user)*, o sistema aciona *EmergencyAssistance*.
- Regras de contexto (IoT): interpretam leituras contínuas de sensores. Exemplo: se um sensor de temperatura reporta mais de 40°C na *kitchen*, o sistema gera um *HighTempAlert*.

- Regras de dependência funcional (IoT): garantem coerência entre dispositivos conectados. Exemplo: se um *switch* está em estado *on* e conectado a uma *lamp*, o grafo infere que a lâmpada também está *on*.

Esse conjunto de regras transforma o grafo em um núcleo semântico que conecta percepção, raciocínio e ação. Ao integrar agentes, objetos e dispositivos IoT em uma mesma base formal, cria-se uma infraestrutura interpretável e escalável, capaz de apoiar decisões em tempo real e oferecer maior robustez às aplicações inteligentes.

2.5. Integração semântica com LLMs e grafos de conhecimento

A integração com *LLMs* proporciona uma interface intuitiva em que o usuário interage através de comandos em linguagem natural, como “Acenda a luz da sala”. Essa camada reduz barreiras técnicas e amplia a acessibilidade, eliminando a necessidade de conhecer formalismos como *RDF* ou *SPARQL*. Os modelos de linguagem atuam como tradutores semânticos, interpretando a intenção do enunciado e conectando-a ao grafo de conhecimento, criando uma ponte entre a comunicação humana e a representação formal necessária para execução de ações no ambiente inteligente.

O fluxo de processamento adota um pipeline híbrido que combina três componentes complementares: o *KG*, que assegura precisão formal e raciocínio lógico sobre entidades e relações; o *RAG*, que enriquece respostas ao recuperar trechos de documentação e ontologias relevantes, fornecendo explicações contextuais; e o *LLM*, que integra ambas as fontes e ajusta a resposta ao perfil e à intenção do usuário. Essa arquitetura equilibra a robustez dos dados estruturados com a flexibilidade da linguagem natural, oferecendo uma solução escalável e interpretável para ambientes inteligentes.




Figura 3: Pipeline híbrido de integração entre LLM, grafo de conhecimento, RAG e dispositivos IoT/robôs. O fluxo mostra a tradução de linguagem natural em consultas formais, enriquecimento contextual, inferência semântica, planejamento de tarefas e execução física, com retorno de observações e geração de explicações interpretáveis.

No nível técnico, os *LLMs* assumem o papel de tradutores semânticos, mapeando comandos em linguagem natural para consultas *SPARQL*. Por exemplo, o pedido “Acenda a luz da sala” é

transformado em uma consulta que verifica no grafo *RDF* o estado da instância *Lampada01* e dispara a ação *TurnOnLight* quando aplicável. O resultado alimenta o planejador multiagente, que delega a execução a dispositivos IoT ou robôs móveis. Além de executar comandos, o sistema retorna respostas explicativas em linguagem natural, como “A luz da sala foi acesa com sucesso”. Essa prática promove transparência e confiança, pois o usuário entende não apenas que a ação foi realizada, mas também os critérios lógicos que a justificaram, em alinhamento com diretrizes de interpretabilidade na Web Semântica.

3. Procedimientos de avaliação

3.1. Criterios de éxito

A avaliação do sistema fundamenta-se em um conjunto reduzido de critérios técnicos e de interação, inspirados nas abordagens do *KnowRob* e do *SAREF*. Em primeiro lugar, a **precisão semântica e consistência lógica** asseguram que o grafo de conhecimento recupere fatos corretos e mantenha coerência durante o raciocínio inferido. Em seguida, a **eficiência e interoperabilidade** medem tanto o tempo de resposta em consultas e regras quanto a capacidade de integrar dispositivos heterogêneos de forma padronizada. A **completude do domínio** verifica se agentes, objetos e dispositivos IoT estão devidamente representados, garantindo cobertura adequada do cenário modelado. Por fim, a **interpretabilidade e satisfação do usuário** avaliam se os resultados são compreensíveis, úteis e inspiram confiança, conectando dados estruturados a uma experiência interativa clara. Esses critérios sintetizam robustez técnica e valor percebido, oferecendo uma avaliação holística do sistema.

- Precisão semântica e consistência lógica
- Eficiência e interoperabilidade
- Completude do domínio
- Interpretabilidade e satisfação do usuário

3.2. Métodos de avaliação

A avaliação dos critérios definidos baseia-se na combinação de métodos técnicos e de interação. Para cada critério, especificam-se os procedimentos adotados e as métricas correspondentes:

- **Precisão semântica e consistência lógica Método:** uso de um *gold standard* de consultas SPARQL e validação com raciocinadores ontológicos ou restrições SHACL. **Métrica:** precisão, *recall* e *F1-score*, além da detecção de inconsistências lógicas.

- **Eficiência e interoperabilidade Método:** medição do tempo de resposta em consultas e regras, bem como testes de integração entre dispositivos heterogêneos. **Métrica:** latência média, throughput de consultas e taxa de integração bem-sucedida.
- **Completeness do domínio Método:** comparação entre os elementos modelados no grafo e os requisitos definidos para o cenário. **Métrica:** cobertura percentual de entidades e relações presentes no domínio.
- **Interpretabilidade e satisfação do usuário Método:** experimentos de interação com participantes, seguidos de questionários padronizados (como o SUS) e entrevistas qualitativas. **Métrica:** taxa de sucesso em tarefas, média de satisfação reportada e clareza das respostas geradas.

A robustez é assegurada pela repetição dos experimentos em múltiplos cenários, enquanto a validade é reforçada pelo uso de validação cruzada nos módulos de classificação e recuperação. Além disso, realiza-se *benchmarking* comparando o pipeline híbrido (*KG + RAG + LLM*) com abordagens puramente conexionistas e puramente simbólicas, demonstrando empiricamente os ganhos em precisão, interpretabilidade e usabilidade.

Referências

IBRAHIM, Nourhan; ABOULELA, Samar; IBRAHIM, Ahmed; KASHEF, Rasha. A survey on augmenting knowledge graphs (KGs) with large language models (LLMs): models, evaluation metrics, benchmarks, and challenges. **Discover Artificial Intelligence**, v. 4, artigo 76, 2024.

GINTING, Muhammad Fadhil; KIM, Sung-Kyun; FAN, David D.; PALIERI, Matteo; KOCHENDERFER, Mykel J.; AGHA-MOHAMMADI, Ali-akbar. SEEK: Semantic Reasoning for Object Goal Navigation in Real World Inspection Tasks. In: **Robotics: Science and Systems**, 2024. arXiv:2405.09822.

LIU, Lihui; WANG, Zihao; TONG, Hanghang. Neural-Symbolic Reasoning over Knowledge Graphs: A Survey from a Query Perspective. **arXiv preprint**, arXiv:2412.10390, 2024.

XU, Jinxuan; JIN, Shiyu; LEI, Yutian; ZHANG, Yuqian; ZHANG, Liangjun. RT-Grasp: Reasoning Tuning Robotic Grasping via Multi-modal Large Language Model. **arXiv preprint**, arXiv:2411.05212, 2024.

OH, Jaehong. Cognitive Synergy Architecture: SEGO for Human-Centric Collaborative Robots. **arXiv preprint**, arXiv:2506.13149, 2025.

XU, Zhentao; CRUZ, Mark Jerome; GUEVARA, Matthew; WANG, Tie; DESHPANDE, Manasi; WANG, Xiaofeng; LI, Zheng. Retrieval-augmented generation with knowledge graphs for customer service question answering. In: INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 47., 2024, Proceedings... **ACM**, 2024. p. 2905-2909.

GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliu; BI, Yuxi; DAI, Yixin; SUN, Jiawei; WANG, Haofen. Retrieval-augmented generation for large language models: A survey. **arXiv preprint**, arXiv:2312.10997, 2024.

CHEN, Zihao; JI, Heng; ZHANG, Yiwei; WANG, Xiaofeng; LI, Zheng. Semantic Scene Graphs for Robotic Applications: A Comprehensive Survey. **IEEE Robotics and Automation Letters**, v. 9, n. 4, p. 3245-3252, 2024.

KUMAR, Ankit; SHARMA, Ravi; PATEL, Neha; JONES, Michael. Multimodal Knowledge Graph Construction for Smart Home Environments. In: **IEEE Internet of Things Journal**, v. 11, n. 8, p. 14521-14535, 2024.